

多因子量化投资框架梳理

核心观点

量化投资的收益来源于风格收益(β)、选股收益(α)和交易收益。风格收益通常是难以预测的，因此，构建量化策略的关键在于产生 Alpha 收益。目前，多因子是量化投资中的主流 Alpha 策略，它通过结合多个具有预测能力的因子来构建投资组合。因此，有效因子的数量以及因子之间的独立性是构建和评价量化策略的关键。在此框架下，为了产生稳健的中性收益或者在指数基础上做增强，风险模型和组合优化，是多因子模型中的重要组成部分。

□ 权益量化投资流程

量化投资策略的构建过程是：数据处理->因子构建->因子加权->组合优化->交易执行。数据的质量和丰富程度，决定了因子的质量和独立性上限，进而决定了整个策略收益的上限。

通常认为风格收益是难以预测的，因此，构建量化策略的关键在于产生 Alpha 收益。Alpha 收益由因子库、风险模型和组合优化共同决定。

在执行端，随着规模的扩大，策略对市场的冲击和交易成本会急剧上升。优化算法能够帮助策略降低交易成本。

□ 当前的量化策略特征

第一，海量级因子。部分投资人使用的因子数量达到万级，通过机器学习加权以规避大量因子共线性的问题。这种做法的问题是策略的底层收益同质化高，策略偏好小市值股票；第二，押注风格，以提升 Beta 收益。部分投资人主动押注某种风格，押对后收益增长显著，但风格切换时，业绩回撤明显，策略波动性提升；第三，策略竞争领域更加广泛，从因子库的竞争，延展到数据环节，执行优化甚至服务器延迟。

□ 端到端与人工智能

展望未来，量化投资可能演化的方向之一是端到端的投资框架。目前，端到端框架有两种认知，一种是从原始数据到因子，无需人工介入；一种是从原始数据到权重输出的完整投资流程。

人工智能正在大力发展推理能力，当获得足够的推理能力后，结合人工智能的知识储备和代码开发能力，能够在量化投资的各个环节提升开发效率，甚至有可能替代人类研究员。

□ 风险提示

部分展示结果由模型计算所得，仅代表历史情况，不可简单外推到未来。

文中总结的框架系统根据可查资料和调查整理所得，与现实情况相比，可能存在遗漏或简化，仅供参考。

部分内容来自于外文文献，受翻译影响，可能与作者本意存在误差，具体信息请以参考原始文献。

分析师：陈奥林

执业证书号：S1230523040002

chenaolin@stocke.com.cn

研究助理：陆达

luda@stocke.com.cn

相关报告

1 《第三阶段：非权重股补涨》

2024.02.18

2 《私募业绩汇编-2024 年 01 月版》 2024.02.08

3 《继续关注地产基建产业链》

2024.02.07

正文目录

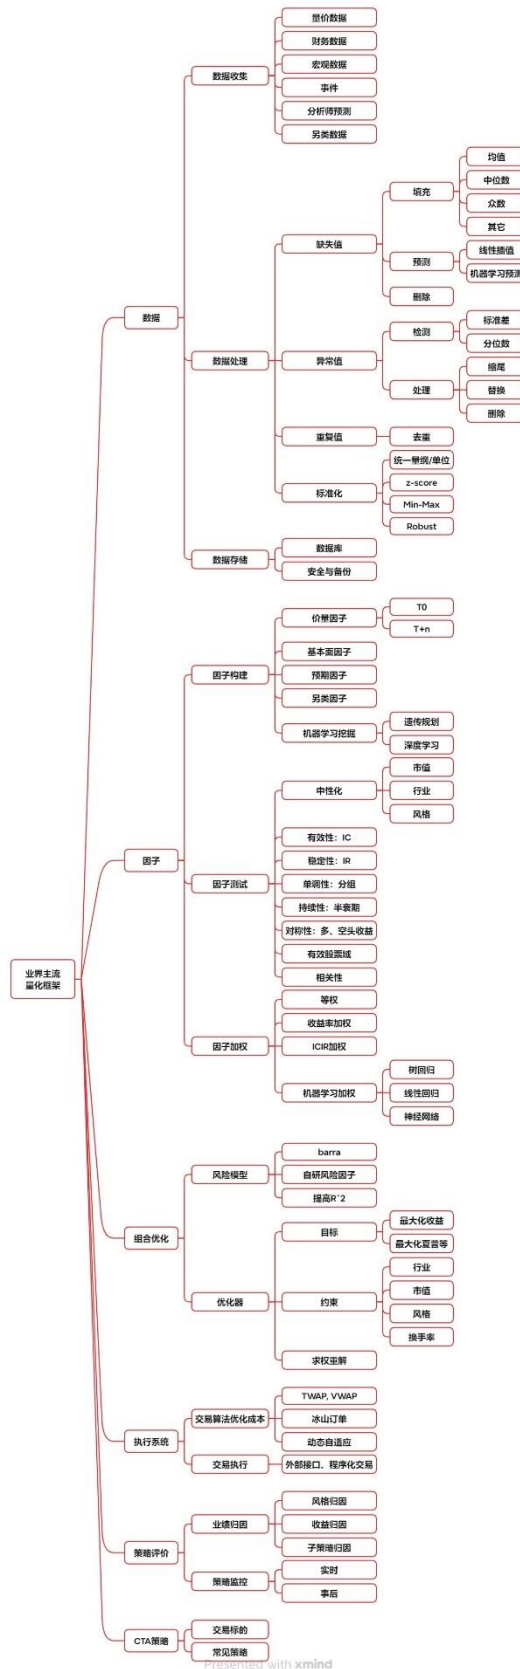
1 主流多因子框架	4
1.1 数据收集与处理	5
1.1.1 数据收集	5
1.1.2 数据处理	6
1.1.3 数据储存	7
1.2 因子	7
1.2.1 因子构建	7
1.2.2 因子测试	8
1.2.3 因子加权	11
1.3 组合优化	12
1.3.1 风险模型	12
1.3.2 组合优化	14
1.4 执行系统	15
1.4.1 算法优化	15
1.4.2 交易执行	16
1.5 策略评价	17
1.5.1 业绩归因	17
1.5.2 策略监控	17
2 CTA 策略	18
2.1 CTA 简介	18
2.2 交易标的	18
2.3 常见策略	18
3 未来展望	18
3.1.1 端到端架构	19
3.1.2 AI 参与	19
4 风险提示	20
5 参考资料	20

图表目录

图 1: 多因子投资框架.....	4
图 2: “特立独行”因子 20 日 IC 及累计 IC	9
图 3: “特立独行”因子分组单调性	10
图 4: 规模因子与其它因子相关性.....	11
图 5: 机器学习因子加权算法年化收益对比.....	12
图 6: DIN(Deep Inception Networks)架构	19
表 1: 相同因子在不同股票池, 表现差异大 (2007 年 1 月至 2023 年 11 月)	11
表 2: CNE6 风格因子归类.....	13
表 3: 执行算法分类.....	16
表 4: 场内权益市场衍生品.....	18

1 主流多因子框架

图1: 多因子投资框架



资料来源: 浙商证券研究所整理

量化投资与主动权益投资核心区别在于决策依据不同。量化投资的决策由模型产生，主动权益投资的决策由投资者产生。虽然主动权益投资者也会用到数理统计模型，但是这些模型产生的信息只是过程变量，最终决策依旧由投资者制定。

目前的主流量化投资框架是基于多因子的综合系统。框架通常包括以下几个关键步骤：数据收集与处理、因子开发、风险模型构建、投资组合优化、执行算法设计和后续的策略执行监控等多个环节。

1.1 数据收集与处理。

1.1.1 数据收集

目前，构建量化投资策略所用到的数据主要为市场价量数据、财务数据、宏观经济数据、新闻事件、分析师预测等数据。

市场价量数据

- 价格数据：各频率的历史价格、实时价格，如开盘价、收盘价、最高价、最低价、VWAP 等。
- 成交量数据：交易量等，反映市场活跃程度和流动性。
- 交易数据：包括买卖订单、成交记录等，用于分析市场供需情况。
- 技术指标：如移动平均线、相对强弱指数（RSI）、布林带等，用于分析市场趋势和波动性。

财务数据

- 公司财报：包括利润表、资产负债表、现金流量表等，提供公司财务状况的详细信息。
- 财务衍生信息：ROE, ROA, 资产负债率等，用于评估公司价值和投资吸引力。
- 财务预测：分析师对公司未来财务表现的预测，如盈利预测、增长预测等。

宏观经济数据

- 国家经济增长、通货膨胀率、失业率、利率水平、贸易数据等。

事件

- 公司新闻：并购、重组、管理层变动、新产品发布等对公司股价有直接影响的事件。
- 行业新闻：行业政策变动、技术进步、市场需求变化等。
- 政治事件：选举结果、政策变动、国际关系等可能影响市场情绪和投资决策的事件。
- 自然灾害：地震、洪水等对特定行业或地区经济有重大影响的事件。

分析师预测

- 盈利预测：分析师对公司未来盈利的预测，影响投资者预期。
- 目标价格：分析师给出的股票目标价格，反映市场对股票未来表现的预期。
- 评级变动：买入、持有、卖出等评级的变化，影响市场情绪。

另类数据

- 包括但不限于社媒数据、新闻媒体、卫星图像、网络搜索、环境数据、专利和知识产权等非标准化、非结构化的数据。

1.1.2 数据处理

数据处理包括缺失值处理，异常值处理，重复值处理以及数据标准化。

缺失值处理

填充法：均值填充、中位数填充、众数填充、最临近填充等；

预测法：线性插值、机器学习预测；

$$\text{线性插值公式: } y(x) = y_1 + \frac{(x-x_1)(y_2-y_1)}{(x_2-x_1)}$$

$$\text{回归插值表达式: } y = f(x; X, Y)$$

删除：直接删除有缺失值的样本。

异常值处理

异常值检测：通过计算标准差或分位数来识别当前数据是否异常

异常值处理：1) 缩尾：设定分位数或标准差阈值，阈值外的值用边界值替代；2) 替换：用均值、中位数、众数等替换；3) 删除有异常值的样本。

重复值处理

识别并删除重复的记录。

标准化

标准化 (Normalization)，在统计学和量化投资领域中，通常指的是将不同量纲和数值范围的数据转换到一个标准或者通用的可比较的尺度下。在量化投资中，因子标准化是一个常见的预处理步骤，它能够帮助去除因子之间的量纲影响，使得不同的股票或者资产之间的因子值具有可比性，也便于组合构建和风险模型的使用。通过数值标准化方法（如 Z-score 标准化、最小—最大标准化等）将数据缩放到统一的范围，通常是到[0, 1]区间或是具有 0 均值和 1 标准差的分布。

- 统一量纲/单位

在量化投资中，量纲是指资产价格、交易量、时间周期、金融比率等数据单位和尺度。正确理解和处理量纲的意义对于确保数据分析的准确性和建模的有效性至关重要。为了使得数据可比，算法性能和模型准确，需要正确处理量纲。

在分析大小市值公司股票的日交易量时，直接比较交易量的绝对值是不合适的，因为大市值公司的交易量通常比小市值公司要大。在这种情况下，需要将交易量除以公司市值来标准化，从而获得一个可以跨公司比较的相对交易量指标。

- z-score 标准化

常用的标准化方法。具体操作是将数值减去样本均值，然后除以其标准差。标准化后的值表示原始值距离均值的标准差数。

$$x_{\text{standardized}} = \frac{x - \mu}{\sigma}$$

- Min-Max 标准化

也称为归一化，它将数值缩放到 0 和 1 之间的范围。

$$x_{\text{normalized}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

- Robust 标准化

传统的 Z-score 标准化方法，即将数据减去其均值后除以标准差，对异常值非常敏感。如果数据集中包含异常值，那么均值和标准差都可能会受到影响，进而影响标准化后的结果。

相比之下，Robust 标准化使用数据的中位数（Median）和四分位数范围（Interquartile Range, IQR）来代替均值和标准差。四分位数范围是第一四分位数（25%分位数）和第三四分位数（75%分位数）之间的差值，它排除了数据集中的极端值。

$$x_{\text{robust}} = \frac{x - M}{IQR}$$

其它的标准化方法还有单位向量标准化，百分位排名标准化等。可根据不同的数据集特性和任务场景，选择合适的标准化方法。

1.1.3 数据储存

根据数据的类型和用途选择合适的存储系统。这可能包括关系型数据库（如 MySQL），非关系型数据库（如 MongoDB），或者专用于时间序列数据的数据库（如 DolphinDB）。

为了防止数据丢失或损坏，需要备份数据。同时需要有数据恢复机制，以保证在数据意外丢失时能够迅速恢复。

1.2 因子

多因子投资框架是目前主流的量化投资框架。多因子投资框架的核心在于识别和利用那些能够持续产生超额收益的因子，并通过科学的组合和风险管理，实现在不同市场环境下的稳健投资回报。这种策略的成功依赖于对因子的深入理解和有效的模型构建。

1.2.1 因子构建

价量因子

价量因子通过分析股票的价格、成交量、价格与成交量之间的关系来揭示市场动态和潜在的投资信号。价量因子包含多个频段，从分钟级别的高频到月频，都可以构建相应的价量因子。根据因子预测的长度和应用场景，量价因子可以被分为两类。

- T0 因子（日内因子）

基于当日（T0）市场数据来预测当日交易表现的因子。这类因子通常用于高频交易策略，如日内交易或算法交易，它们依赖于实时或近实时的市场信息，如价格变动、交易量、订单流等。

T0 因子的例子包括价格动量、成交量异常、市场深度变化等。这些因子的预测通常在几分钟到几小时内有效。

- T+n 因子（多日因子）

$T+n$ 因子，或称为多日因子，是指那些基于历史数据来预测未来一段时间（如几天、几周或几个月）内市场表现的因子。这类因子适用于中长期投资策略。

在实际应用中，根据交易策略的需求选择合适的因子类型。 $T0$ 因子适用于需要快速反应市场变化的策略，而 $T+n$ 因子则适用于那些基于长期市场趋势和周期的策略。

基本面因子

基本面因子是基于公司财务数据、行业状况、宏观经济指标等基本面信息构建的投资因子。这些因子旨在反映公司的真实经济价值和价值的潜在增长能力。

另类因子

不属于传统基本面或量价因子范畴的、用于量化投资策略中的非传统投资因子。这些因子通常基于非传统数据源或独特的分析方法，目标是提供独立和差异化的收益来源。另类因子可能基于社交媒体情绪、新闻报道、专利数据、卫星图像、消费者行为数据等非传统数据。

机器学习挖掘因子

利用机器学习算法从大量数据中自动发现和提取的潜在投资因子。通过机器学习模型来识别海量数据中的模式和关系，从而用于投资决策。机器学习模型，尤其是神经网络，能够捕捉数据中的非线性关系，这在传统的统计模型中可能难以实现。机器学习算法能够有效处理高维数据，这对于金融市场中的大数据应用尤为重要。

常见的机器学习挖掘算法有遗传规划、深度神经网络（LSTM, GRU, Transformer）等。

1.2.2 因子测试

因子测试目的在于对潜在投资因子的有效性进行评估。尽量使得所选因子能够在实际交易中产生超额收益，并且能够适应市场的变化。一个有效的因子测试可以帮助投资者构建更稳健的投资组合，降低风险，提高投资回报。

因子中性化

因子中性化旨在消除因子投资组合对某些特定因子的暴露，以减少这些因子对投资组合表现的影响。这些特定因子通常包括市值、行业和风格类因子。常用截面回归进行因子中性化，中性化后的因子表达式：

$$\epsilon_i = f_i - \left(\alpha + \beta_m m_i + \sum_{j=1}^J \beta_{Ij} I_{ij} + \sum_{k=1}^N \beta_k S_{ik} \right)$$


f_i 是股票 i 的因子值。 m_i 是股票 i 的市值因子值。 I_{ij} 是股票 i 对应的行业哑变量， j 表示行业编号， J 是行业总数。 S_{ik} 是股票 i 的第 k 个风格因子值。

有效性测试：IC

衡量因子值的排序与未来收益排序之间的相关性。Rank IC 的计算基于因子值的排名（Rank）和未来收益之间的关系。

$$\text{Rank IC} = \frac{\sum_{i=1}^N (R_{\text{rank}(i)} - \bar{R}) \cdot (F_{\text{rank}(i)} - \bar{F})}{\sqrt{\sum_{i=1}^N (R_{\text{rank}(i)} - \bar{R})^2 \cdot \sum_{i=1}^N (F_{\text{rank}(i)} - \bar{F})^2}}$$

图2: “特立独行”因子 20 日 IC 及累计 IC



资料来源: Wind, 浙商证券研究所

稳定性测试: IR

因子投资中, 使用 Rank IC 的均值除以其标准差来计算信息比率 (IR)。IR 衡量的是因子在时序上的稳定性。

$$IR = \frac{\overline{IC}}{\sigma_{IC}}$$

单调性测试: 分组

观察因子值与未来收益之间的关系是否呈现出单调性, 即因子值的增加是否总是伴随着未来收益的增加 (正单调性), 或者因子值的增加是否总是伴随着未来收益的减少 (负单调性)。单调性测试通常涉及以下步骤:

1. 因子值排序: 将股票根据因子值进行排序。
2. 分组: 将排序后的股票分为多个组 (例如, 10 组)。
3. 计算组内平均收益: 对于每个组, 计算组内股票的平均未来收益。
4. 分析单调性: 观察组内平均收益与因子值之间的关系, 判断是否存在单调性。

如果存在正单调性, 我们可以期望看到随着因子值的增加, 组内平均收益也增加; 如果存在负单调性, 那么随着因子值的增加, 组内平均收益会减少。这种关系可以通过绘制因子值与组内平均收益的柱状图来直观地展示。


正单调性可以表示为:

$$\forall i, j \in \{1, 2, \dots, N\}, i < j \Rightarrow f_i < f_j \Rightarrow R_i \leq R_j$$

负单调性可以表示为:

$$\forall i, j \in \{1, 2, \dots, N\}, i < j \Rightarrow f_i < f_j \Rightarrow R_i \geq R_j$$

图3: “特立独行”因子分组单调性



资料来源: Wind, 浙商证券研究所

持续性测试: 半衰期

因子的半衰期是指因子收益率下降到其初始值一半所需的时间。它是衡量因子持续性的一个重要指标。测算因子半衰期的一般步骤如下:

1. 计算因子收益。
2. 计算因子收益的时间序列。
3. 估计自相关系数。
4. 拟合衰减函数:

假设因子收益的自相关系数随时间呈指数衰减, 可以使用如下衰减函数来拟合自相关系数:

$$\rho(t) = \rho_0 e^{-\lambda t}$$

5. 求解半衰期:

$$T_{1/2} = \frac{\ln(2)}{\lambda}$$

对称性测试: 多、空收益

在 A 股市场, 由于做空限制, 投资者可能无法直接实施空头策略, 但可以通过其他方式来模拟空头策略, 通过构建虚拟的空头组合 (例如, 选择因子值最低的一组股票作为空头组合的代理)。

在量化投资中, 对称性测试通常用于检验因子在多头和空头策略中的表现是否一致。在 A 股市场, 由于不能直接做空, 因此空头策略的应用受到限制, 这可能影响因子测试的完整性。如果一个因子的收益率主要是空头组贡献, 那该因子实际可投资性会受到影响。

分域测试

在进行因子有效性测试时, 区分不同的股票池 (如沪深 300 和中证 1000) 可以帮助投资者更好地理解因子在不同市场细分中的表现。沪深 300 通常包含市值较大、流动性较好的股票, 而中证 1000 则包含了市值较小、波动性可能较高的股票。对这两个不同的股票池

进行因子测试，可以揭示因子在不同市场环境下的适用性和稳定性。一些因子，在全 A 股票池有效性高，但是限定在沪深 300 股票池内，有效性消失。

表1：相同因子在不同股票池，表现差异大（2007 年 1 月至 2023 年 11 月）

因子	全 A 股票池 IC, IR(20 日)		沪深 300 股票池 IC, IR(20 日)	
买入锁仓	8.21%	1.26	1.04%	0.100
特立独行	8.06%	1.21	0.84%	0.081
月内日均换手	-8.26%	-0.95	0.27%	0.021

资料来源：Wind, 浙商证券研究所

相关性检验


因子的相关性检验（Factor Correlation Test）是评估不同因子之间是否存在相关性的统计方法。相关性检验有助于了解因子之间的线性关系，这对于构建多因子模型和避免多重共线性至关重要。如果因子之间高度相关，那么它们可能在提供信息时存在冗余，这可能导致模型的预测能力下降。

对于两个因子 X 和 Y，它们之间的相关系数 r 可以表示为：

$$r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

在构建多因子模型时，需要避免多重共线性，这通常意味着因子之间的相关性不应超过某个阈值。常见的阈值是 0.3 或 0.5。如果两个因子相关性较高，可以正交后再检验因子的有效性。

图4：规模因子与其它因子相关性



资料来源：Wind, 浙商证券研究所

1.2.3 因子加权

在量化投资中，因子加权是指根据某些标准或规则为投资组合中的各个因子分配不同的权重。这种加权方法可以帮助投资者优化投资组合，提高风险调整后的收益。

等权重

每个因子分配相同的权重，不考虑因子的预测能力或风险。

收益率加权

利用因子的动量效应，基于因子的近期回报表现来分配权重。

$$w_i = \frac{r_i}{\sum_{j=1}^N r_j} \quad \forall i = 1, 2, \dots, N$$

w_i 是因子 i 的权重, r_i 是归一化后的因子 i 的近期收益率, N 是因子的总数。

ICIR 加权

基于因子的 IC 或 IR 来分配因子权重, 这种加权方法偏好近期有效性较高或者表现比较稳定的因子。

$$w_i = \frac{IR_i}{\sum_{j=1}^N IR_j} \quad \forall i = 1, 2, \dots, N$$

机器学习加权

• 树回归模型

使用历史因子值和预期收益率, 训练树模型 (通常使用梯度提升树如 XGB, LGBM, CATB)。将因子值作为特征输入模型, 输出预期收益率的估计。


• 线性回归模型

使用历史因子值和预期收益率, 训练线性模型 (通常使用的线性模型如 OLS, Lasso, ElasticNet)。将因子值作为特征输入模型, 输出预期收益率的估计。

• 神经网络加权

使用历史因子值和预期收益率, 训练神经网络模型 (通常使用的模型如 MLP, LSTM, GRU)。将因子值作为特征输入模型, 输出预期收益率的估计。

图5: 机器学习因子加权算法年化收益对比



资料来源: Wind, 浙商证券研究所

1.3 组合优化

得到最终的个股因子值后, 进行组合优化是一个关键步骤, 旨在构建一个约束条件下的最大化收益或风险调整后收益的投资组合。组合优化通常涉及以下几个步骤: 构建风险模型、确定优化目标、确定约束条件, 求解个股权重。

1.3.1 风险模型

对于市场中性策略和指数增强策略, 需要通过风险模型来识别市场风险和基准的风格, 以便实现稳健的 Alpha 收益。中性产品旨在通过对冲基准的市场风险和风格 (如市

值、行业等风格因子）来实现与市场无关的 Alpha 收益。而指增产品跟踪基准的市场风险和风格，通过 Alpha 策略来获取超额收益。

风险模型在这一过程中扮演着至关重要的角色，它帮助投资者识别和量化投资组合相对于基准的系统性风险。通过将基准收益分解为不同风险因子的贡献，投资者可以更精确地调整投资组合的因子暴露，以实现中性和指增的投资目标。

MSCI Barra 的 CNE6 模型是中国 A 股市场广泛使用的风险模型，模型中包含了 1 个国家因子、16 个风格因子以及 32 个行业因子。风格因子可归为 8 类：规模因子(Size)、波动率因子(Volatility)、流动性因子(Liquidity)、价值因子(Value)、质量因子(Quality)、动量因子(Momentum)、成长因子(Growth)、分红因子(Dividend Yield)。CNE6 的简化表示如下：

$$R_i = f_c + \sum_{j=1}^{N_{\text{Industry}}} \beta_{i,j} F_{\text{Industry},j} + \sum_{k=1}^{N_{\text{Style}}} \beta_{i,k} F_{\text{Style},k} + \epsilon_i$$

其中， R_i 是股票收益， f_c 是国家因子， F_{Industry} 是行业因子， F_{Style} 是风格因子。

表2：CNE6 风格因子归类

一级因子	二级因子	因子描述
size 规模因子	LNCAP	对数市值
	MIDCAP	中等市值
Volatility 波动率因子	Beta	市场风险
	Residual Volatility	残余波动率，由历史 sigma、日超额收益标准差、累积收益范围构成。
Liquidity 流动性因子	STOM	月换手率
	STOQ	季换手率
	STOA	年换手率
	ATVR	年化交易量比率
Value 价值因子	BTOP	账面市值比
	Earnings Yield	由现金盈利价格比 (CETOP)、EP 比 (ETOP)、企业倍数 (EM)、分析师预测 EP 比 (ETOPF) 构成
	Long Term Reversal	由长期相对强度 (LTRSTR) 和长期历史 Alpha (LTHALPHA) 构成
	Leverage	由市场杠杆率 (MLEV)、账面杠杆率 (BLEV) 和资产负债率 (DTOA) 三个三级因子构成
Quality 质量因子	Earnings Variability	由收入变动率 (VSAL)、盈利变动率 (VERN)、现金流变动率 (VFLO)、预测每股收益变动率 (ETOPF_STD) 四个三级因子构成
	Earnings Quality	由资产负债表盈余 (ABS) 和现金流盈余 (ACF) 两个三级因子构成
	Profitability	由资产周转率 (ATO)、毛利 (GP)、毛利率 (GPM)、资产收益率 (ROA) 四个三级因子构成

表2: CNE6 风格因子归类

一级因子	二级因子	因子描述
	Investment Quality	由总资产增长率 (AGRO)、发行股份增长率 (IGRO)、资本支出增长率 (CXGRO) 三个三级因子构成
Momentum 动量因子	RSTR	相对强度
	HALPHA	历史 Alpha
Growth 成长因子	EGRLF	分析师预测长期 (3-5 年) 净利润增长率
	EGRO	每股净利润增长率
	SGRO	每股收入增长率
Dividend Yield 分红因子	DTOP	过去 12 个月每股分红/上月末股价
	DTOPF	未来 12 个月每股预测分红/现股价

资料来源: MSCI, 浙商证券研究所

1.3.2

组合优化

组合优化的目标是在满足一系列条件约束的条件下, 实现投资组合的最优配置。通过多因子投资框架, 最优配置的问题可以转化为最大化 Alpha 因子暴露的问题。

优化目标

- 最大化预期收益。
- 最大化风险调整后收益等。

条件约束

- 资产权重约束: 确保每只股票的权重在预设的上下限之间, 例如, 单个股票的权重不能超过投资组合总资产的一定比例。
- 行业或风格暴露约束: 限制投资组合在特定行业或风格因子上的暴露, 以避免过度集中或偏离投资策略。
- 风险约束: 设定投资组合的总体风险 (如波动率) 不超过某个阈值, 或者与某个基准指数的风险水平保持一致。
- 流动性约束: 确保投资组合的流动性满足交易和资金需求, 避免因流动性不足导致的交易成本增加。
- 换手率的约束: 防止投资组合频繁交易, 从而降低交易成本和减少市场冲击。

以下是一个简化的组合优化问题。

目标函数 (以预期收益最大化为例):

$$\text{Maximize } \sum_{i=1}^N w_i \cdot E(R_i)$$

条件约束

- 资产权重之和为 1（完全投资）:

$$\sum_{i=1}^N w_i = 1$$

- 个股权重约束（避免过度集中或过度分散）:

$$w_{\min,i} \leq w_i \leq w_{\max,i} \quad \forall i = 1, 2, \dots, N$$

- 行业暴露约束:

$$w_{\min,ind} \leq \sum_i w_i \cdot \beta_{i,ind} \leq w_{\max,ind}$$

- 风格暴露约束:

$$w_{\min,s} \leq \sum_i w_i \cdot \beta_{i,s} \leq w_{\max,s}$$

- 风险约束（例如，总风险不超过某个阈值）:

$$\sqrt{\sum_{i=1}^N \sum_{j=1}^N w_i \cdot w_j \cdot \sigma_{ij}} \leq \text{Risk Threshold}$$

- 换手率约束（限制交易频率）:

$$\text{Turnover} \leq \text{Target Turnover}$$

当明确了目标和约束条件后，可以通过优化算法来找到满足所有条件的最优解。

1.4 执行系统

量化投资在交易时往往涉及大量股票。为了在实际市场中以最优或接近最优的价格执行交易指令，同时最小化交易成本和市场冲击，并满足交易的时效性要求，往往采用程序化交易的方式执行交易指令，而非人工执行。

1.4.1 算法优化

常用的执行算法主要包括以下几种。

时间加权平均价格（Time-Weighted Average Price, TWAP）

这种算法旨在一定时间内以平均价格执行交易，通常用于大额交易，以减少市场冲击。

成交量加权平均价格（Volume-Weighted Average Price, VWAP）

VWAP 算法根据市场成交量分布来分配交易量，目标是在成交量高的时段执行更多的交易。

固定价格执行（Fixed Price Execution）

在这种策略中，交易以预设的固定价格执行，不考虑市场价格的波动。

冰山算法（Iceberg Orders）

类似于 VWAP，冰山算法将大额订单分割成多个小额订单，逐步执行，以避免对市场价格产生显著影响。

动态阿尔法 (Dynamic Alpha)

这种算法结合了市场预测和执行策略，试图在执行交易的同时捕捉市场波动带来的额外收益。

自适应算法 (Adaptive Algorithms)

自适应算法根据实时市场数据动态调整交易策略，以优化执行效果。

表3: 执行算法分类

类型	策略
减少冲击	冰山订单(Ice berg)、隐藏订单 (Hidden Order) 等算法
静联加减仓	大宗交易、保证成交量加权平均价格算法(Guaranteed VWAP)等
变易执行	交易量加权平均价格 (VWAP)、时间加权平均价格(TWAP) 等
快速执行	市场直通(Direct Market Access), 及攻击性算法(Aggressive Algorithms) 等

资料来源：上交所，浙商证券研究所

1.4.2 交易执行

程序化交易和服务器部署是实现高效、自动化交易的关键技术。

程序化交易

程序化交易，是指使用计算机程序来执行交易策略的过程。这种方法允许投资者根据预设的规则和模型自动执行交易，无需人工干预。

速度：程序化交易可以在毫秒级别执行大量交易，远超过人类交易员的速度。

一致性：自动化系统可以确保交易策略的一致执行，不受情绪波动的影响。

成本效率：长期来看，程序化交易可以降低交易成本，尤其是在高频交易（HFT）中。

风险管理：程序化交易可以实时监控市场条件，快速响应风险事件，自动执行止损和止盈策略。

服务器部署

服务器部署对于量化交易至关重要，它涉及到交易系统的稳定性、安全性和性能。

低延迟：在高频交易中，服务器的物理位置和网络连接对交易速度至关重要。通常，服务器会部署在交易所附近的数据中心，以减少数据传输延迟。

高可靠性：服务器需要具备高可靠性，以确保在市场波动时能够稳定运行，避免系统故障导致的交易中断。

安全性：服务器部署需要考虑数据安全和网络安全，防止未经授权的访问和潜在的网络攻击。

可扩展性：随着交易量的增加，服务器部署需要能够灵活扩展，以支持更多的交易和数据处理需求。

灾难恢复：服务器部署应包括灾难恢复计划，以防系统故障，确保业务连续性。

1.5 策略评价

1.5.1 业绩归因

对业绩进行拆解是一种重要的分析方法，它可以帮助投资者理解策略收益的来源。

风格归因分析

使用归因分析，将投资组合的收益与基准指数的收益进行比较。分析收益的来源，包括市场风险（Beta）、行业暴露、风格因子（如价值、动量、质量等）的暴露，并与基准指数在风格因子上的暴露进行对比。

超额收益归因

将投资组合的收益与基准指数的收益进行比较，识别超额收益（Alpha）和基准收益。

将 Alpha 收益进一步拆解为不同因子的贡献。这通常涉及到对策略中使用的因子进行分析，以确定哪些因子对 Alpha 收益贡献最大。使用统计方法（如回归分析）来量化每个因子对 Alpha 收益的贡献。

子策略归因

测算不同子策略的收益以及仓位占比，推算不同子策略所贡献的收益。

1.5.2 策略监控

当量化策略投入实盘交易后，管理人需要通过一系列监控和管理工具来确保策略的有效执行和风险控制。以下是一些关键的监控和管理步骤：

实时监控

使用实时监控系統跟踪策略的执行情况，包括交易执行、滑点、交易成本等。

性能评估

定期评估策略的实际表现，与预期收益和风险进行对比，分析策略的有效性。

风险管理

实时监控投资组合的风险指标，如波动率、最大回撤、VaR 等，并在风险超出预设阈值时采取相应措施。

异常检测

设计算法来识别和报告交易异常，如异常的交易量、价格波动或系统故障。

交易执行监控

监控交易执行的效率，确保交易按照策略设定的条件和参数执行。

合规性检查

确保所有交易活动遵守相关法律法规和交易所规则，定期进行合规性审查。

策略调整

根据市场变化和策略表现，适时调整策略参数或交易逻辑。

报告和记录

记录交易活动和策略表现，为策略回顾和未来优化提供数据支持。

2 CTA 策略

2.1 CTA 简介

CTA (Commodity Trading Advisor) 策略, 即商品交易顾问策略, 是一种在期货市场中寻求盈利的投资策略。CTA 策略通常由专业的交易顾问 (CTA) 管理, 他们使用各种技术分析和量化模型来预测市场趋势, 并据此进行交易。

一般认为, CTA 策略与主流的量化多头、指数增强策略、市场中性策略的相关性比较低。CTA 策略可以为投资者提供一种在不同市场环境下寻求收益的方式, 尤其是在传统资产类别表现不佳的时候。因此, 众多管理人会将部分仓位分配给 CTA 策略, 以达到整体的增强效果。

2.2 交易标的

与权益市场关联度比较高的可投标的, 主要有股指期货和 ETF 期权。除此之外, CTA 策略可以投资于多种期货市场, 包括农产品、金属、能源、外汇、利率等。

表4: 场内权益市场衍生品

类型	标的
股指期货	上证 50(IH)、沪深 300(IF)、中证 500(IC)、中证 1000(IM)
期权	上证 50ETF、沪深 300ETF、中证 500ETF、创业板 ETF、 科创 50ETF、科创板 50ETF

资料来源: 浙商证券研究所整理

2.3 常见策略

• 趋势策略

这是 CTA 策略中常用策略之一, 它基于市场趋势进行交易。策略会识别并跟随市场的主要趋势, 无论是上升趋势还是下降趋势。

• 套利策略

套利策略利用不同市场或不同合约之间的价格差异。CTA 可能会同时买入低估的资产和卖出高估的资产, 以期从价格差异中获利。

• 高频交易 (HFT):

高频交易策略利用算法和高速计算机技术, 在极短的时间内进行大量交易, 以从微小的价格差异中获利。

3 未来展望

因子投资框架起始于 1960 年代哈里·马科维茨 (Harry Markowitz) 的现代投资组合理论 (MPT)。1964 年, 威廉·夏普 (William Sharpe) 提出了资本资产定价模型 (Capital Asset Pricing Model, CAPM), 这是第一个将风险因子与预期收益联系起来的模型。1980 年代, 经过法玛和弗兰奇 (Fama and French) 的完善, 发展出现代多因子投资框架的雏形。1990 年代后, 因子投资逐渐落地商业化应用, 并演进发展至今。

展望未来, 量化投资框架可能有两个方面的演化趋势。首先, 随着数据和算力的发展, 端到端的投资架构开始显露雏形。其次, AI 的快速发展使得其有可能在量化投资中扮演更重要的角色。

3.1.1 端到端架构

目前，业界对“端到端”投资架构一般有两种认知。

从数据到因子

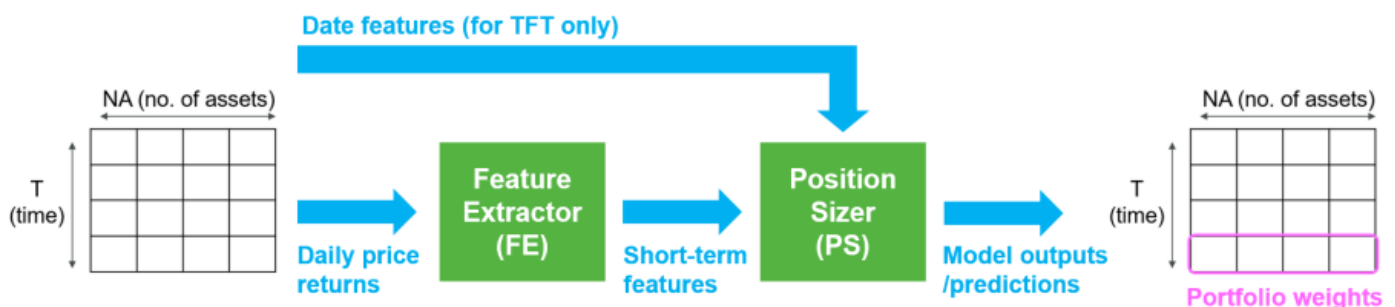
第一种，端到端的一端是指原始数据（如量价数据，财务数据等），另一端是指被构建的因子，通常被称为自动化因子发现（Automated Factor Discovery）或因子挖掘（Factor Mining）。这种方法的核心在于利用先进的数据分析技术和机器学习算法（如深度学习、遗传规划），来自动从原始数据中提取和构建投资因子，而不需要人工进行因子逻辑的思考。这种方法的优势在于能够处理大规模数据集，发现复杂的非线性关系，并可能揭示人类分析师难以察觉的投资逻辑。然而，这种方法也引起了争议，如模型的可解释性、过拟合风险以及对市场结构变化的适应性。

从数据到权重

第二种，端到端的一端是指原始数据或最低限度处理的数据，另一端是资产的配置权重。这种架构能够实现自动化的完整量化投资流程。它从原始数据或经过最低限度处理的数据开始，经过一系列的数据处理、分析和模型构建步骤，最终输出资产的配置权重。这种架构的目标是实现量化投资策略的全自动化，减少人为干预，提高策略的执行效率和一致性。

目前，有潜力或初步实现第二种端到端架构的代表有强化学习算法和 DIN 架构。

图6: DIN(Deep Inception Networks)架构



资料来源：Deep Inception Networks: A General End-to-End Framework for Multi-asset Quantitative Strategies, 浙商证券研究所整理

3.1.2 AI 参与

在量化投资的流程中，人工智能（AI）可以在多个环节发挥作用，提高策略的开发、执行和监控效率。以下是 AI 在量化投资中的主要应用。

数据收集与处理

AI 可以自动化收集和清洗大量结构化和非结构化数据，如市场数据、新闻报道、社交媒体内容等。使用自然语言处理（NLP）技术分析文本数据，提取关键信息和市场情绪。目前已有的框架有 FinGPT 和 Marketsense。

代码开发

目前 AI 在代码开发层面的能力已被证实。量化投资的数据处理、因子开发、组合优化等环节都需要大量代码开发和优化，AI 在这些环节能提升开发效率，提升代码质量。

全流程 AI

逻辑推理能力是目前 AI 模型发展的主要方向之一。当 AI 具备足够的逻辑推理能力后，可在量化投资的各个环节设置不同的 AI 代理人。给定明确目标后，AI 代理人自行推理，编写代码。因子挖掘环节，可设置大量 AI 代理人，构建因子并评估因子。将前一环节的结果反馈至下一环节的 AI 代理人，实现全流程 AI 决策和执行。

4 风险提示

部分展示结果由模型计算所得，仅代表历史情况，不可简单外推到未来。

文中总结的框架系统根据可查资料和调查整理所得，与现实情况相比，可能存在遗漏或简化，仅供参考。

部分内容来自于外文文献，受翻译影响，可能与作者本意存在误差，具体信息请参考原始文献。

5 参考资料

- [1] 《机器学习与因子一：特征工程算法测评》，浙商证券研究所
- [2] 《中国股票风险因子模型白皮书》，清华大学全球证券研究院
- [3] China A Total Marker Equity Model for Long-Term Investors, MSCI, BAARA,
- [4] A five-factor asset pricing model. Journal of financial economics, Fama, E. F., & French, K. R.
- [5] Deep Inception Networks: A General End-to-End Framework for Multi-asset Quantitative Strategies, Tom Liu, Stephen Roberts, Stefan Zohren

股票投资评级说明

以报告日后的 6 个月内，证券相对于沪深 300 指数的涨跌幅为标准，定义如下：

1. 买入：相对于沪深 300 指数表现 + 20% 以上；
2. 增持：相对于沪深 300 指数表现 + 10% ~ + 20%；
3. 中性：相对于沪深 300 指数表现 - 10% ~ + 10% 之间波动；
4. 减持：相对于沪深 300 指数表现 - 10% 以下。

行业的投资评级：

以报告日后的 6 个月内，行业指数相对于沪深 300 指数的涨跌幅为标准，定义如下：

1. 看好：行业指数相对于沪深 300 指数表现 + 10% 以上；
2. 中性：行业指数相对于沪深 300 指数表现 - 10% ~ + 10% 以上；
3. 看淡：行业指数相对于沪深 300 指数表现 - 10% 以下。

我们在此提醒您，不同证券研究机构采用不同的评级术语及评级标准。我们采用的是相对评级体系，表示投资的相对比重。

建议：投资者买入或者卖出证券的决定取决于个人的实际情况，比如当前的持仓结构以及其他需要考虑的因素。投资者不应仅仅依靠投资评级来推断结论。

法律声明及风险提示

本报告由浙商证券股份有限公司（已具备中国证监会批复的证券投资咨询业务资格，经营许可证编号为：Z39833000）制作。本报告中的信息均来源于我们认为可靠的已公开资料，但浙商证券股份有限公司及其关联机构（以下统称“本公司”）对这些信息的真实性、准确性及完整性不作任何保证，也不保证所包含的信息和建议不发生任何变更。本公司没有将变更的信息和建议向报告所有接收者进行更新的义务。

本报告仅供本公司的客户作参考之用。本公司不会因接收人收到本报告而视其为本公司的当然客户。

本报告仅反映报告作者的出具日的观点和判断，在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的投资建议，投资者应当对本报告中的信息和意见进行独立评估，并应同时考量各自的投资目的、财务状况和特定需求。对依据或者使用本报告所造成的一切后果，本公司及/或其关联人员均不承担任何法律责任。

本公司的交易人员以及其他专业人士可能会依据不同假设和标准、采用不同的分析方法而口头或书面发表与本报告意见及建议不一致的市场评论和/或交易观点。本公司没有将此意见及建议向报告所有接收者进行更新的义务。本公司的资产管理公司、自营部门以及其他投资业务部门可能独立做出与本报告中的意见或建议不一致的投资决策。

本报告版权均归本公司所有，未经本公司事先书面授权，任何机构或个人不得以任何形式复制、发布、传播本报告的全部或部分内容。经授权刊载、转发本报告或者摘要的，应当注明本报告发布人和发布日期，并提示使用本报告的风险。未经授权或未按要求刊载、转发本报告的，应当承担相应的法律责任。本公司将保留向其追究法律责任的权利。

浙商证券研究所

上海总部地址：杨高南路 729 号陆家嘴世纪金融广场 1 号楼 25 层

北京地址：北京市东城区朝阳门北大街 8 号富华大厦 E 座 4 层

深圳地址：广东省深圳市福田区广电金融中心 33 层

上海总部邮政编码：200127

上海总部电话：(8621) 80108518

上海总部传真：(8621) 80106010

浙商证券研究所：<https://www.stocke.com.cn>